

November 19, 2024

1 Estado del arte

1.1 Inteligencia artificial aplicada al eCommerce

1.1.1 Definición y evolución de la IA en el comercio electrónico

La inteligencia artificial (IA) ha experimentado un crecimiento acelerado en el comercio electrónico, transformándose desde herramientas básicas de automatización hasta sistemas avanzados de personalización.

Inicialmente, la IA se aplicaba en la gestión de inventarios y en la automatización de tareas repetitivas, lo que mejoraba la eficiencia operativa. Con el desarrollo de algoritmos de aprendizaje profundo y el incremento de datos disponibles, se han implementado sistemas de recomendación, análisis predictivo, chatbots y asistentes virtuales.

Estos avances buscan ofrecer experiencias de usuario personalizadas y optimizar estrategias de marketing, lo que incrementa la competitividad en un mercado digital en constante cambio.

1.1.2 Aplicaciones clave de la IA en el eCommerce

- **Chatbots y asistentes virtuales:** Utilizando técnicas de Procesamiento de Lenguaje Natural (NLP), los chatbots responden de forma automatizada y personalizada a las consultas de los usuarios. A través del aprendizaje continuo de interacciones previas, estos sistemas mejoran la precisión de sus respuestas y predicen necesidades de los clientes. Por ejemplo, el chatbot de H&M sugiere productos basándose en la selección del usuario, optimizando el proceso de compra y reduciendo la carga de trabajo en atención al cliente.
- **Análisis de sentimientos:** Permite a las empresas analizar grandes volúmenes de opiniones y comentarios para identificar tendencias y posibles problemas emergentes. Mediante técnicas de NLP, se pueden analizar datos de reseñas y redes sociales, ajustando en tiempo real estrategias de marketing. El uso de este análisis es clave en plataformas como eBay, que ajusta sus recomendaciones y campañas de marketing basadas en las percepciones de los usuarios.
- **Sistemas de recomendación:** Emplean algoritmos de aprendizaje profundo y filtrado colaborativo para personalizar la experiencia de compra sugiriendo productos relevantes. En plataformas como Amazon, los sistemas de recomendación analizan tanto el comportamiento de los usuarios como las características de los productos, incrementando la probabilidad de compra y mejorando la fidelización.

1.2 Sistemas de recomendación en eCommerce

Los sistemas de recomendación son herramientas que ayudan a los usuarios a descubrir productos, servicios o información que puedan ser de su interés. Estos sistemas son ampliamente utilizados en plataformas como Netflix, Amazon, Spotify, entre otros, para personalizar la experiencia del usuario.

1.2.1 Filtrado colaborativo: Definición y concepto teórico

El filtrado colaborativo es una técnica de recomendación que se basa en las interacciones y preferencias de múltiples usuarios para predecir y recomendar elementos que podrían ser de interés para un usuario específico. A diferencia de otros enfoques, como el filtrado basado en contenido, el filtrado colaborativo no requiere información explícita sobre los atributos de los ítems, sino que se apoya en las relaciones entre usuarios e ítems.

El fundamento del filtrado colaborativo es que si un grupo de usuarios ha mostrado preferencias similares en el pasado, es probable que tengan preferencias similares en el futuro. De esta manera, las recomendaciones se generan a partir de las similitudes entre usuarios o entre ítems.

1.2.2 Tipos de filtrado colaborativo

Filtrado colaborativo basado en vecinos

Basado en usuarios (User-Based)

- Se centra en encontrar usuarios similares al usuario objetivo y recomendar ítems que estos usuarios hayan valorado positivamente.
- Utiliza métricas como la similitud del coseno, correlación de Pearson o distancia euclidiana para medir la similitud entre usuarios.
- Identifica los k usuarios más similares al usuario objetivo.
- Agrega las preferencias de los vecinos para recomendar ítems no vistos por el usuario objetivo.

Por ejemplo, si el usuario A y el usuario B han calificado positivamente una serie de películas similares, se podría recomendar al usuario A una película que el usuario B ha calificado altamente pero que el usuario A aún no ha visto.

Basado en ítems (Item-Based)

- En lugar de buscar usuarios similares, este método busca ítems similares a aquellos que el usuario ha mostrado interés.
- Se utilizan métricas similares a las del enfoque basado en usuarios para medir la similitud entre ítems, recomendando ítems que son similares a los que el usuario ha valorado positivamente.

Por ejemplo, si un usuario ha disfrutado de una película como “El señor de los anillos”, el sistema puede recomendar otras películas de ciencia ficción con temáticas similares como la serie “Juego de tronos”.

Filtrado colaborativo basado en modelos

a. Factores de matriz (Matrix factorization)

La factorización de matrices se origina en los modelos de factores latentes, los cuales postulan la existencia de variables ocultas que caracterizan tanto a los usuarios como a los productos. Por ejemplo, es posible representar películas mediante dos factores numéricos: una dimensión que oscila entre comedia y seriedad, y otra entre realidad y fantasía.

En la primera dimensión, un valor elevado indica una película más seria, mientras que un valor bajo sugiere una mayor inclinación hacia la comedia. De manera análoga, en la segunda dimensión, un valor alto refleja una mayor tendencia hacia la fantasía, y un valor bajo denota un apego a la realidad. Estos factores latentes también se aplican a los usuarios; por ejemplo, un usuario con un valor alto en la primera dimensión preferirá películas serias, y uno con un valor alto en la segunda dimensión mostrará predilección por películas de fantasía.

Con esta representación, tanto usuarios como películas pueden modelarse mediante vectores. Un usuario que disfruta significativamente de películas serias y de fantasía podría ser representado por el vector:

$$\mathbf{u}_1 = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$$

Por otro lado, un usuario que prefiere comedias y es indiferente entre fantasía y realidad podría ser descrito por:

$$\mathbf{u}_2 = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$$

Del mismo modo, podemos asignar vectores a dos películas específicas: una película seria y de fantasía como *El Señor de los Anillos*, y una comedia realista como *Mean Girls*. Sus vectores serían:

$$\mathbf{p}_1 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \quad \mathbf{p}_2 = \begin{bmatrix} -3 \\ -3 \end{bmatrix}$$

Para modelar las calificaciones que cada usuario otorgaría a cada película, se utiliza la combinación lineal de los vectores de usuarios y películas. Por ejemplo, la calificación que el usuario \mathbf{u}_1 daría a la película \mathbf{p}_1 se calcula mediante el producto punto:

$$\mathbf{u}_1^T \mathbf{p}_1 = 3 \times 2 + 4 \times 4 = 6 + 16 = 22$$

Si se hace esto para todos los usuarios y películas, se tiene el siguiente sistema lineal:

$$\mathbf{R} = \mathbf{U}\mathbf{P}^T,$$

donde

$$\mathbf{U} = \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \end{bmatrix} = \begin{bmatrix} 3 & 4 \\ -2 & 0 \end{bmatrix}, \quad \mathbf{P} = \begin{bmatrix} \mathbf{p}_1^T \\ \mathbf{p}_2^T \end{bmatrix} = \begin{bmatrix} 2 & 4 \\ -3 & -3 \end{bmatrix}$$

Y

$$\mathbf{R} = \begin{bmatrix} \mathbf{u}_1^T \mathbf{p}_1 & \mathbf{u}_1^T \mathbf{p}_2 \\ \mathbf{u}_2^T \mathbf{p}_1 & \mathbf{u}_2^T \mathbf{p}_2 \end{bmatrix} = \begin{bmatrix} 22 & -21 \\ -4 & 6 \end{bmatrix}$$

Este modelo refleja que el usuario \mathbf{u}_1 , quien prefiere películas serias y de fantasía, otorga una calificación más alta a *El Señor de los Anillos* que a *Mean Girls*. Contrariamente, el usuario \mathbf{u}_2 aficionado a las comedias, muestra la preferencia opuesta.

En la práctica, los valores de las matrices \mathbf{U} y \mathbf{P} son desconocidos; únicamente disponemos de ciertas entradas de la matriz \mathbf{R} . El desafío consiste en estimar de manera precisa las matrices \mathbf{U} y \mathbf{P} .

Este problema es una instancia de la descomposición en valores singulares (SVD), con la peculiaridad de que no se tienen todas las entradas de la matriz \mathbf{R} , sino solo una pequeña proporción de ellas.

El objetivo es, entonces, encontrar matrices \mathbf{U} y \mathbf{P} de rango K que satisfagan la aproximación $\mathbf{R} \approx \mathbf{UP}^T$. De este modo, la calificación estimada que el usuario i asigna al artículo j se expresa como:

$$\hat{r}_{ij} = \mathbf{u}_i^T \mathbf{p}_j$$

Para evaluar la proximidad entre el producto de matrices y \mathbf{R} , se utilizan diferentes funciones de pérdida. Una métrica común es la raíz del error cuadrático medio (RMSE), calculada como:

$$\text{RMSE} = \sqrt{\frac{1}{|\mathcal{A}|} \sum_{(i,j) \in \mathcal{A}} (r_{ij} - \mathbf{u}_i^T \mathbf{p}_j)^2}$$

donde r_{ij} es la calificación real del usuario i al artículo j , \mathcal{A} es el conjunto de pares (i, j) para los cuales se conoce r_{ij} , y $|\mathcal{A}|$ es el número total de calificaciones.

En esencia, el RMSE representa la raíz cuadrada del promedio de los cuadrados de las diferencias entre las calificaciones estimadas y las reales.

Otra métrica frecuentemente utilizada es el error absoluto medio (MAE), definido por:

$$\text{MAE} = \frac{1}{|\mathcal{A}|} \sum_{(i,j) \in \mathcal{A}} |r_{ij} - \mathbf{u}_i^T \mathbf{p}_j|$$

El RMSE suele ser preferible en contextos donde los errores de predicción pequeños no son significativos, ya que penaliza de manera más severa los errores grandes en comparación con el MAE.

Para minimizar el RMSE, el problema se plantea como:

$$\min_{\mathbf{U}, \mathbf{P}} \sum_{(i,j) \in \mathcal{A}} [(r_{ij} - \mathbf{u}_i^T \mathbf{p}_j)^2 + \lambda (\|\mathbf{p}_j\|^2 + \|\mathbf{u}_i\|^2)]$$

donde λ es un parámetro de regularización que ayuda a prevenir el sobreajuste al penalizar la complejidad de los vectores de usuarios y productos.

b. Modelos probabilísticos

Los modelos probabilísticos en el filtrado colaborativo se basan en la teoría de la probabilidad para modelar las interacciones entre usuarios e ítems. Estos modelos asumen que las interacciones observadas (como calificaciones o clics) son el resultado de procesos estocásticos subyacentes que pueden ser capturados mediante distribuciones de probabilidad. La ventaja principal de este enfoque es su capacidad para manejar la incertidumbre y proporcionar estimaciones probabilísticas de las preferencias de los usuarios, lo que puede mejorar la robustez y la interpretabilidad de las recomendaciones.

i. Modelos de mezcla y factorización de matrices bayesianas

Uno de los enfoques más destacados dentro de los modelos probabilísticos es la factorización de matrices bayesianas. Estos modelos extienden las técnicas de factorización de matrices tradicionales (como Singular Value Decomposition, SVD) incorporando priors bayesianos sobre los factores latentes, lo que permite una inferencia más flexible y una mejor generalización en escenarios con datos escasos.

ii. Factorización de matrices bayesianas

En la factorización de matrices bayesianas, se modela la matriz de interacciones R (donde $R_{u,i}$ representa la interacción del usuario u con el ítem i) como el producto de dos matrices latentes U y V , donde cada entrada de U y V está distribuida de acuerdo con una distribución previa. Formalmente, se puede expresar como:

$$R_{u,i} \sim \mathcal{N}(U_u V_i^T, \sigma^2)$$

donde U_u y V_i son los vectores latentes para el usuario u y el ítem i , respectivamente, y \mathcal{N} denota una distribución normal con media $U_u V_i^T$ y varianza σ^2 . Además, se definen priors sobre U y V , típicamente gaussianos:

$$U_u \sim \mathcal{N}(0, \lambda_U^{-1} I)$$

$$V_i \sim \mathcal{N}(0, \lambda_V^{-1} I)$$

Este enfoque permite la incorporación de conocimiento previo y la regularización automática, ayudando a prevenir el sobreajuste y mejorando la capacidad del modelo para generalizar a nuevos datos.

iii. Inferencia y aprendizaje:

La inferencia en modelos de factorización de matrices bayesianas generalmente se realiza mediante métodos de inferencia variacional o Markov Chain Monte

Carlo (MCMC), que buscan aproximar la distribución posterior de los factores latentes U y V dado los datos observados. El objetivo es maximizar la probabilidad posterior de los parámetros latentes, lo que se logra iterativamente ajustando las estimaciones de U y V para minimizar la divergencia de Kullback-Leibler entre la distribución aproximada y la distribución posterior real.

Ventajas:

- **Manejo de incertidumbre:** Proporciona estimaciones probabilísticas que capturan la incertidumbre en las predicciones.
- **Regularización automática:** Los priors bayesianos ayudan a evitar el sobreajuste, especialmente en escenarios con datos escasos.
- **Flexibilidad:** Permite la incorporación de diferentes tipos de datos y priors personalizados según el dominio de aplicación.

Desventajas:

- **Complejidad computacional:** Los métodos de inferencia probabilística pueden ser computacionalmente costosos, especialmente para grandes conjuntos de datos.
- **Escalabilidad:** A medida que aumenta la dimensión de la matriz de interacciones, el costo de la inferencia puede volverse prohibitivo.

c. **Redes neuronales**

Las redes neuronales han emergido como una herramienta poderosa en el filtrado colaborativo, gracias a su capacidad para modelar relaciones no lineales y capturar patrones complejos en los datos de interacción entre usuarios e ítems. Las arquitecturas de redes neuronales profundas permiten aprender representaciones ricas y abstractas de los usuarios e ítems, mejorando significativamente la calidad de las recomendaciones.

- Autoencoders para recomendaciones:** Los autoencoders son una clase de redes neuronales utilizadas para aprender representaciones compactas de los datos mediante un proceso de codificación y decodificación. En el contexto de sistemas de recomendación, los autoencoders se utilizan para aprender representaciones latentes de los usuarios e ítems a partir de la matriz de interacciones R .
- Arquitectura de autoencoders:** Un autoencoder típico consta de dos partes principales:
 - **Encoder:** Mapea la entrada (por ejemplo, las interacciones de un usuario) a un espacio latente de menor dimensión.
 - **Decoder:** Reconstruye la salida a partir de la representación latente, intentando replicar la entrada original.

En sistemas de recomendación, el encoder puede tomar las interacciones de un usuario con diferentes ítems y mapearlas a una representación latente que capture las preferencias subyacentes del usuario. El decoder, a su vez, intenta predecir las interacciones faltantes o futuras del usuario a partir de esta representación latente.

Ventajas de los autoencoders:

- **Captura de relaciones complejas:** Pueden modelar interacciones no lineales y relaciones complejas entre usuarios e ítems.
 - **Reducción de dimensionalidad:** Aprenden representaciones latentes compactas que facilitan el procesamiento y la recomendación.
 - **Flexibilidad:** Pueden integrarse con otros tipos de datos y características adicionales para mejorar las recomendaciones.
- iii. **Redes neuronales convolucionales (CNNs) para recomendaciones:**
 Las CNNs, conocidas por su éxito en el procesamiento de datos espaciales como imágenes, también se han adaptado para sistemas de recomendación. En este contexto, las CNNs pueden capturar patrones locales y relaciones espaciales en las interacciones usuario-ítem, mejorando la precisión de las recomendaciones.
- Aplicación de CNNs en recomendaciones:**
- **Captura de patrones espaciales:** Las CNNs pueden identificar patrones locales en la matriz de interacciones que podrían pasar desapercibidos para otros modelos.
 - **Integración con datos de contenido:** Las CNNs pueden combinar datos de interacción con datos de contenido (como imágenes de productos) para generar recomendaciones más ricas y contextuales.
- iv. **Ejemplos de redes neuronales en recomendaciones:**
- **DeepCoNN:** Una arquitectura que utiliza dos redes neuronales convolucionales para modelar las interacciones de usuarios e ítems por separado antes de combinarlas para predecir calificaciones.
 - **Neural Collaborative Filtering (NCF):** Combina técnicas de filtrado colaborativo con redes neuronales profundas para aprender interacciones no lineales entre usuarios e ítems.
- v. **Ventajas de las redes neuronales:**
- **Capacidad de aprender representaciones complejas:** Pueden capturar interacciones no lineales y relaciones de alta dimensión entre usuarios e ítems.
 - **Escalabilidad y flexibilidad:** Las arquitecturas pueden adaptarse y escalarse según la complejidad de los datos y las necesidades del sistema.
 - **Integración de múltiples fuentes de información:** Permiten la incorporación de datos adicionales (como contenido multimedia) para enriquecer las recomendaciones.
- vi. **Desventajas:**
- **Requerimientos computacionales:** Las redes neuronales profundas requieren recursos computacionales significativos para el entrenamiento y la inferencia.
 - **Complejidad de la implementación:** La configuración y optimización de arquitecturas de redes neuronales puede ser compleja y requiere experiencia técnica avanzada.
 - **Interpretabilidad:** Los modelos basados en redes neuronales pueden ser menos interpretables en comparación con enfoques más simples como la factorización de matrices.

d. Filtrado colaborativo basado en sistemas híbridos

Combina múltiples enfoques de recomendación para aprovechar las ventajas de cada uno y mitigar sus limitaciones. Por ejemplo, combinar filtrado colaborativo con filtrado basado en contenido o integrar diferentes técnicas dentro del filtrado colaborativo.

1.2.3 Métricas de similitud

Para evaluar la similitud entre usuarios o ítems, se emplean diversas métricas:

Similitud del coseno Mide el coseno del ángulo entre dos vectores de calificación.

$$\text{Sim}(A, B) = \frac{A \cdot B}{\|A\| \|B\|}$$

Correlación de Pearson Evalúa la correlación lineal entre las calificaciones de dos usuarios.

$$\text{Sim}(A, B) = \frac{\sum (A_i - \bar{A})(B_i - \bar{B})}{\sqrt{\sum (A_i - \bar{A})^2} \sqrt{\sum (B_i - \bar{B})^2}}$$

Distancia euclidiana Calcula la distancia directa entre dos vectores de calificación.

$$\text{Dist}(A, B) = \sqrt{\sum (A_i - B_i)^2}$$

1.2.4 Desafíos del filtrado colaborativo

A pesar de su efectividad, el filtrado colaborativo enfrenta varios desafíos técnicos:

I. Escasez de datos (Sparsity)

En sistemas con una gran cantidad de ítems y usuarios, la matriz de interacción suele ser muy dispersa, lo que dificulta la identificación de patrones de similitud.

Soluciones:

- Utilizar técnicas de factorización de matrices para inferir valores faltantes.
- Implementar métodos de imputación de datos.

II. Arranque en frío (Cold Start)

Dificulta la recomendación para nuevos usuarios o ítems que no tienen suficientes interacciones registradas.

Soluciones:

- Incorporar información adicional mediante filtrado basado en contenido.
- Emplear sistemas híbridos que combinen múltiples fuentes de información.

III. Escalabilidad

El aumento en la cantidad de usuarios e ítems puede impactar negativamente el rendimiento de los algoritmos basados en vecinos.

Soluciones:

- Optimizar cálculos mediante estructuras de datos eficientes.
- Utilizar algoritmos de aproximación y técnicas de reducción de dimensionalidad.

IV. Sincronización de preferencias

Las preferencias de los usuarios pueden cambiar con el tiempo, lo que requiere que los sistemas actualicen continuamente sus modelos.

Soluciones:

- Implementar modelos dinámicos que consideren la evolución temporal de las preferencias.
- Utilizar ventanas de tiempo para ponderar más las interacciones recientes.

2 Casos de uso en grandes plataformas.

El estado actual de la inteligencia artificial en el eCommerce muestra una evolución continua hacia sistemas más avanzados y personalizados. Las aplicaciones de IA en este ámbito, como los chatbots, el análisis de sentimientos y los sistemas de recomendación, han optimizado significativamente la experiencia del usuario y los procesos de venta. Sin embargo, aún existen desafíos, como la escalabilidad, la escasez de datos y los sesgos éticos.

Las grandes plataformas, como Amazon y Netflix, han demostrado el éxito de la integración de enfoques híbridos, ofreciendo importantes lecciones sobre adaptabilidad e innovación para futuras investigaciones en este campo.

2.1 Amazon

Amazon utiliza una combinación avanzada de algoritmos de recomendación y análisis de datos para personalizar la experiencia de compra de sus usuarios. Entre sus tecnologías y características principales se destacan:

- **Sistemas de recomendación:** Mediante el uso de IA, Amazon sugiere productos basándose en el historial de compras y navegación del usuario. Las recomendaciones abarcan categorías como “productos relacionados”, “los clientes que compraron esto también compraron” y “recomendaciones personalizadas”.
- **Análisis predictivo:** Amazon predice la demanda de productos utilizando análisis predictivo para optimizar su inventario, lo que permite una gestión eficiente de stock y tiempos de entrega.
- **Chatbots y asistentes virtuales:** Alexa, el asistente de voz de Amazon, permite a los usuarios realizar compras mediante comandos de voz, mejorando la accesibilidad y facilidad de compra.

- **Optimización de precios:** Amazon ajusta sus precios en tiempo real a través de algoritmos de IA que maximizan la competitividad y las ventas, adaptándose a las fluctuaciones del mercado.

Gracias a estas tecnologías, Amazon ofrece una experiencia personalizada, permitiendo a los usuarios encontrar productos de interés con mayor rapidez, lo cual incrementa la probabilidad de compra y la satisfacción del cliente. Las estrategias de recomendación y optimización de precios han demostrado ser efectivas en el aumento de las ventas y en la retención de clientes.

2.2 Netflix

Netflix implementa sistemas de recomendación avanzados que identifican y sugieren contenido relevante para cada usuario. Este sistema se basa en:

- **Algoritmos de recomendación:** Netflix utiliza algoritmos de aprendizaje automático para sugerir películas y series, tomando en cuenta el historial de visualización y preferencias previas de cada usuario.
- **Perfilado de usuarios:** La plataforma construye perfiles detallados que permiten entender mejor los gustos de los usuarios y adaptar las recomendaciones en consecuencia.
- **Pruebas A/B:** Netflix realiza constantes pruebas A/B para evaluar y optimizar tanto la interfaz de usuario como las recomendaciones, asegurando que la experiencia del usuario sea intuitiva y atractiva.

Las recomendaciones personalizadas de Netflix ayudan a retener a los usuarios en la plataforma, promoviendo el consumo de contenido y aumentando el tiempo de visualización. Este sistema mejora notablemente la satisfacción del usuario al proporcionar contenido relevante y atractivo.

2.3 Spotify

Spotify utiliza inteligencia artificial para generar recomendaciones musicales personalizadas, facilitando el descubrimiento de nueva música:

- **Algoritmos de recomendación:** Las playlists personalizadas como “Discover Weekly” y “Daily Mix” son producto de algoritmos que analizan el historial de escucha del usuario y adaptan las recomendaciones en función de sus preferencias (Spotify’s Recommendation System).
- **Análisis de datos:** Spotify analiza grandes cantidades de datos de escucha para identificar patrones y tendencias musicales, mejorando la relevancia de sus recomendaciones (Spotify Data Analysis).
- **Filtrado colaborativo:** Utilizando técnicas de filtrado colaborativo, Spotify recomienda canciones que otros usuarios con gustos similares han escuchado, fomentando la exploración musical (Spotify’s Recommendation System).

Las recomendaciones personalizadas en Spotify mejoran la experiencia de los usuarios, quienes descubren música nueva acorde a sus gustos, lo cual incrementa su fidelidad a la plataforma. Este sistema también aumenta el tiempo de permanencia de los usuarios en la plataforma (Spotify Data Analysis).

2.4 Alibaba

Alibaba emplea inteligencia artificial para optimizar la experiencia de compra y potenciar las ventas mediante:

- **Recomendaciones personalizadas:** Alibaba utiliza IA para recomendar productos a sus usuarios, basándose en el comportamiento de compra y navegación, lo que mejora la relevancia de las sugerencias.
- **Asistentes virtuales:** Tmall Genie, un asistente virtual de Alibaba, ayuda a los usuarios en sus compras, proporcionando una experiencia interactiva y eficiente.
- **Análisis de sentimiento:** Alibaba analiza reseñas y opiniones para comprender mejor la percepción de los usuarios sobre los productos, lo cual permite ajustes en la oferta y la mejora de servicios.

Las recomendaciones personalizadas de Alibaba han demostrado incrementar las ventas de la plataforma y mejorar la satisfacción del cliente. El uso de asistentes virtuales y análisis de sentimiento optimiza la calidad del servicio, ofreciendo una experiencia de compra más satisfactoria y enfocada en las necesidades de los clientes.

Referencias

References

- [1] Alibaba Cloud. (s.f.). *How Alibaba uses AI*. <https://www.alibabacloud.com/>
- [2] Amazon Science. (s.f.). *Amazon's recommendation algorithm*. <https://www.amazon.science/>
- [3] Amazon Web Services. (s.f.). *AWS Amazon Personalize*. <https://aws.amazon.com/personalize/>
- [4] Arévalo, J. (2020). *Desarrollo de un sistema de recomendación basado en filtrado colaborativo* [Tesis de grado, Universidad Politécnica Salesiana]. Repositorio Institucional UPS. <https://dspace.ups.edu.ec/bitstream/123456789/25026/1/UPS->
- [5] Barrios, J. (s.f.). *El filtrado colaborativo y los motores de recomendación*. <https://www.juanbarrios.com/el-filtrado-colaborativo-y-los-motores-de-recomendacion/>
- [6] Bawack, R. E., Gómez, L. M., & Pérez, A. (2022). Artificial intelligence in E-Commerce: A bibliometric study and literature review. *Electronic Markets*, 32(1), 99–114. <https://link.springer.com/article/10.1007/s12525-022-00537-z>
- [7] García, J. L. (2019). *Sistema de recomendación de objetos de aprendizaje a través de filtrado colaborativo* [Tesis de grado, Universidad de La Rioja]. Repositorio Institucional Universidad de La Rioja. <https://documat.unirioja.es/download/articulo/6382579.pdf>

- [8] IBM. (s.f.). *¿Qué es el filtrado basado en contenido?*. <https://www.ibm.com/es-es/topics/content-based-filtering>
- [9] Jannach, D., Zanker, M., Felfernig, A., & Friedrich, G. (2018). Métricas de similaridad y evaluación para sistemas de recomendación de filtrado colaborativo. *Revista Iberoamericana de Tecnología e Innovación*, 3(2), 45–60. <https://riti.es/index.php/riti/article/view/109>
- [10] MFAIA. (s.f.). *Sistemas de recomendación: ¿qué son y cómo funcionan?*. <https://mfaia.dia.fi.upm.es/sistemas-de-recomendacion-personalizando-la-experiencia-del-usuario-en-la-era-dig>
- [11] PeerDH. (s.f.). *Implementación de sistemas de recomendación híbridos que combinan filtrado colaborativo y métodos basados en contenido*. <https://peerdh.com/es/blogs/programming-insights/implementing-hybrid-recommendation-systems-combining-collaborative-filtering-and->
- [12] PeerDH. (s.f.). *Sistemas de Recomendación Híbridos: Combinando Técnicas de Filtrado Colaborativo y Basado en Contenido*. <https://peerdh.com/es/blogs/programming-insights/hybrid-recommendation-systems-combining-collaborative-and-content-based-filtering>
- [13] Pajuelo Holguera, F. (2021). *Sistemas de recomendación basados en filtrado colaborativo: Aceleración mediante computación reconfigurable y aplicaciones predictivas sensoriales* [Tesis de grado, Universidad de Extremadura]. Repositorio Institucional Universidad de Extremadura. https://dehesa.unex.es/bitstream/10662/12476/1/TDUEX_2021_Pajuelo_Holguera.pdf
- [14] Pajuelo Holguera, F. (2021). *Sistemas de recomendación basados en filtrado colaborativo* [Tesis de grado]. Universidad de Extremadura. <https://dialnet.unirioja.es/servlet/tesis?codigo=291402>
- [15] Salesforce. (s.f.). *Cinco maneras de usar la IA en el comercio electrónico*. <https://www.salesforce.com/es/blog/ai-in-ecommerce/>
- [16] Soria Flores, E. R. (2023). *Inteligencia artificial como estrategia de innovación en empresas de servicios*. *Revista Publicando*, 5(2), 123–135. <https://revistapublicando.org/revista/index.php/crv/article/view/2359>
- [17] Soria Flores, E. R. (2024). *Inteligencia artificial (IA) y experiencia del cliente desde el año 2016: Revisión de bibliografía*. https://www.researchgate.net/publication/380563464_Inteligencia_artificial_IA_y_experiencia_del_cliente_desde_el_ano_2016_Revision_de_bibliografia/fulltext/66437b547091b94e93273908/Inteligencia-artificial-IA-y-experiencia-del-cliente-desde-el-ano-2016-Revision-pdf
- [18] Spotify Engineering Blog. (s.f.). *Spotify's recommendation system*. <https://engineering.atspotify.com/>
- [19] Wu, Y. (2019). *Towards reliability in collaborative filtering recommender systems* [Doctoral dissertation, Universidad Politécnica de Madrid]. Repositorio Institucional UPM. <https://oa.upm.es/54719/>

- [20] COMUNICAWEB. (s.f.). *La Inteligencia Artificial en el eComerce.* <https://comunica-web.com/blog/marketing-digital/ia-ecommerce-inteligencia-artificial/>
- [21] Netflix Tech Blog. (s.f.). *How Netflix uses AI.* <https://netflixtechblog.com/>